

1. 实验概览

- 模型架构：BERT-Base-Uncased
- 数据集：GLUE/CoLA（语料库的语言可接受性数据集）
- 训练参数：
 - 训练轮次（epochs）：3
 - 随机种子（random_seed）：42
 - 硬件加速：启用GPU
 - 任务类型：单句分类任务（TaskForSingleSentenceClassification）
- 执行的攻击类型：
 - 安全攻击：数据投毒攻击（PoisoningAttack）
 - 隐私攻击：无执行记录

2. 基准性能分析

- 未获取正常训练（normalTrain）结果，缺少基准性能对比。
- 建议：需补充正常训练实验以建立准确率/F1分数基线（文献中BERT-Base在CoLA任务上的Matthews相关系数基准约60-80%）。

3. 安全攻击分析

数据投毒攻击（PoisoningAttack）

- 攻击原理：通过污染训练数据集（注入恶意样本）破坏模型学习过程。
- 攻击参数：
 - 投毒率：15%
 - 训练轮次：15（高于全局配置的3轮次）

- 性能影响：

指标	数值
准确率	0.400
F1分数	0.375

- 关键发现：
 - 模型性能严重退化，表明投毒攻击成功削弱分类能力（典型CoLA任务中BERT模型准确率应>80%）。
 - 攻击后F1分数（0.375）反映模型对正负样本的判别能力显著失衡。

4. 隐私攻击分析

- 模型反演（RLMI）、梯度反演（FET）、模型窃取（ModelStealingAttack）均无实验数据，暂不分析。

5. 横向对比分析

安全攻击特性对比

评估维度	投毒攻击
性能影响	高（准确率↓60%）
检测难度	中等（依赖数据审计）
缓解成本	高（需重训模型）

关键风险评估

- 最大业务威胁**：数据投毒攻击（直接导致模型失效）
- 最高合规风险**：训练数据污染（可能违反数据完整性规范）
- 最紧急漏洞**：未防护的训练管道（缺乏投毒检测机制）

6. 防御建议

- 针对性防御措施**：
 - 部署数据清洗层（如KNN离群值检测）过滤恶意样本
 - 采用鲁棒训练方法（如差分隐私或对抗训练）
- 监控指标**：
 - 训练损失突变（ $>30\%$ ）
 - 验证集准确率异常波动（连续epoch下降 $>5\%$ ）
- 架构改进**：
 - 实现训练数据版本控制与哈希校验
 - 引入联邦学习架构分散数据风险

7. 结论

本次实验针对BERT-Base模型在GLUE/CoLA任务执行数据投毒攻击，投毒率15%导致模型准确率降至0.400（预期基准 >0.80 ），F1分数降至0.375，**证实模型对训练数据污染高度脆弱**。攻击通过扩展训练轮次（ $15>3$ ）强化了破坏效果，反映出当前训练管道缺乏数据完整性验证机制。

关键风险集中于投毒攻击导致的模型功能失效，可能引发业务中断与合规违规。建议优先实施三阶段防御：

- 预防层**：训练前数据哈希校验与离群检测
- 缓解层**：鲁棒优化算法（如Elastic Weight Consolidation）
- 响应层**：实时监控验证集性能漂移

进一步实验需补充：

- 不同投毒率（5%-30%）的性能影响曲线
- 启用防御（如数据清洗）后的效果验证
- 跨任务迁移性测试（如SST-2情感分析）

未来研究方向包括：

- 开发轻量级实时投毒检测模型
- 探索基于零样本学习的污染数据识别

附录：指标解释

- 准确率 (Accuracy)**：分类正确的样本比例
- F1分数 (F1-Score)**：精确率与召回率的调和平均，衡量分类平衡性
- 投毒率 (Poisoning Rate)**：恶意样本占训练集的比例